

Data Science.  
Lectures. Weeks 3-4.  
Обобщённый метод наименьших квадратов  
Мороз Екатерина

## Contents

<b>1</b>	<b>Классическая ЛММР</b>	<b>2</b>
	(Линейная модель множественной регрессии)	
1.1	Обычный метод наименьших квадратов . . . . .	2
1.2	Теорема Гаусса-Маркова для КЛММР . . . . .	3
<b>2</b>	<b>Мультиколлинеарность</b>	<b>3</b>
2.1	Полная мультиколлинеарность . . . . .	3
2.2	Частичная (практическая) мультиколлинеарность . . . . .	3
2.3	Признаки мультиколлинеарности . . . . .	4
2.4	Последствия мультиколлинеарности . . . . .	4
2.5	Как бороться с мультиколлинеарностью? . . . . .	4
<b>3</b>	<b>Обобщенная ЛММР, обобщенный МНК</b>	<b>5</b>
3.1	МНК для КЛММР и ОЛММР . . . . .	6
3.2	ОМНК для ОЛММР . . . . .	6
3.3	Выводы: . . . . .	7
3.4	Частный случай: ЛММР с гетероскедастическими (и некоррелированными) ошибками . . . . .	7

# 1 Классическая ЛММР (Линейная модель множественной регрессии)

Матричная форма записи:  $Y = X\beta + \varepsilon$

$Y$  –  $n$ -мерный вектор наблюдений за переменной  $y$ , снятых с объектов, попавших в выборку;

$X$  – матрица ( $n \times k$ ), где  $k$  – это количество регрессоров (объясняющих переменных), включая константу,

$n$  – объем выборки.

$X$  – детерминированная (неслучайная) матрица:

Объекты, попавшие в выборку, имеют неслучайные значения;

При изменении выборки матрица  $X$  не меняется, меняется только  $\varepsilon$  – за счет этого будет меняться  $Y$ .

$E(\varepsilon) = 0$  – случайная ошибка в среднем отсутствует (мат. ожидание равно 0)

Все дисперсии случайных ошибок одинаковы:  $\sigma^2$  (неизвестна)

$V(\varepsilon) = E(\varepsilon\varepsilon^T) = \sigma^2 I_n$  – случайные ошибки не коррелируют.

**Ковариационная матрица вектора случайных ошибок**

$$E\varepsilon\varepsilon^T = E \begin{pmatrix} \varepsilon_1 \\ \dots \\ \varepsilon_n \end{pmatrix} (\varepsilon_1 \quad \dots \quad \varepsilon_n) = (E\varepsilon_i\varepsilon_j)_{i,j=1,\dots,n} = \begin{pmatrix} \sigma^2 & \dots & 0 \\ \dots & \dots & \dots \\ 0 & \dots & \varepsilon_n \end{pmatrix} = \sigma^2 I_n$$

$$\text{cov}(\varepsilon_i\varepsilon_j) = E\varepsilon_i\varepsilon_j = \begin{cases} \sigma^2, & i = j \\ 0, & i \neq j \end{cases}$$

## 1.1 Обычный метод наименьших квадратов

(МНК; OLS - ordinary least squares)

$$\hat{\beta}_{\text{МНК}} = (X^T X)^{-1} X^T Y$$

**Теорема:**

Полученные оценки являются несмещенными

Вектор средних значений для  $\hat{\beta}_{\text{МНК}}$ :  $E(\hat{\beta}_{\text{МНК}}) = \beta$

**Доказательство:**

$$\hat{\beta}_{\text{МНК}} = (X^T X)^{-1} X^T (X\beta + \varepsilon) = (X^T X)^{-1} X^T \beta + (X^T X)^{-1} X^T \varepsilon = \beta + (X^T X)^{-1} X^T \varepsilon$$

$$E(A\xi) = AE(\xi)$$

**Ковариационная матрица вектора  $\hat{\beta}_{\text{МНК}}$**

$$V(\hat{\beta}_{\text{МНК}}) = \sigma^2 (X^T X)^{-1}$$

**Доказательство:**

$$V(\hat{\beta}_{\text{МНК}}) = E(\hat{\beta}_{\text{МНК}} - \beta)(\hat{\beta}_{\text{МНК}} - \beta)^T = E((X^T X)^{-1} X^T \varepsilon [(X^T X)^{-1} X^T \varepsilon]^T) =$$

$$= (X^T X)^{-1} X^T E(\varepsilon\varepsilon^T) X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1}$$

$$(AB)^T = B^T A^T; (A^{-1})^T = (A^T)^{-1}$$

## 1.2 Теорема Гаусса-Маркова для КЛММР

$\hat{\beta}_{\text{МНК}}$  обладает свойством оптимальности:

Если рассмотреть  $K$  - класс всех оценок  $\beta_j$ , несмещенных и линейных по  $y_1 \dots y_n$ , то  $D\hat{\beta}_j = \min D\tilde{\beta}$

### Доказательство:

1)  $\hat{\beta}_{\text{МНК},j} \in K_j$  ( $E\hat{\beta}_{\text{МНК}} = \beta$ ;  $\hat{\beta} = (X^T X)^{-1} X^T Y$  - линейная функция от  $Y$ )

2)  $\varphi_c(\beta) = c^T \beta = c_1 \beta_1 + \dots + c_k \beta_k$  - параметр для оценивания

$c = (c_1 \dots c_k)^T, c_j = \text{const}$  (по  $Y$ )

$K_c = \{b^T Y\}$  - класс оценок для  $c^T \beta$

$b \in R^n$  - может зависеть от  $X$

Докажем, что  $D(c^T \hat{\beta}_{\text{МНК}}) \leq D(b^T Y) \forall b^T Y \in K_c$

2.1)  $c^T \hat{\beta}_{\text{МНК}} \in K_c$  :

-  $E c^T \hat{\beta} = c^T \beta$  - несмещенность

-  $c^T \hat{\beta} = c^T (X^T X)^{-1} X^T Y = b_0^T Y$  - линейность

2.2)  $D(c^T \hat{\beta}) = E(c^T \hat{\beta} - c^T \beta)^2 = E[c^T (\hat{\beta} - \beta)] [\dots]^T = E[c^T (\hat{\beta} - \beta)(\hat{\beta} - \beta)^T c] =$   
 $= c^T (E(\hat{\beta} - \beta)(\hat{\beta} - \beta)^T) c = \sigma^2 c^T (X^T X)^{-1} c$

$E(A\xi B) = A(E\xi B)$

3) Условие несмещенности:

$E(b^T Y) = E(b^T (X\beta + \varepsilon)) = b^T X\beta + b^T E\varepsilon = b^T X\beta \equiv c^T \beta \implies b^T X = c^T$

$E c^T \hat{\beta} = c^T \beta = b^T X\beta$

4)  $D(b^T Y) = E(b^T Y - c^T \beta)^2 = E(b^T (X\beta + \varepsilon) - c^T \beta)^2 = E(b^T X\beta - c^T \beta + b^T \varepsilon)^2 =$   
 $= E(b^T \varepsilon)(b^T \varepsilon)^T = E(b^T \varepsilon \varepsilon^T b) = b^T (E\varepsilon \varepsilon^T) b = \sigma^2 b^T b \geq 0$

## 2 Мультиколлинеарность

$\varepsilon_i$

$y_i = \beta_1 + \beta_2 x_i^{(2)} + \dots + \beta_k x_i^{(k)} + \varepsilon_i, i = 1, \dots, n$

$Y = X\beta + \varepsilon, X - (n \times k)$

$E\varepsilon = O_n, V(\varepsilon) = \sigma^2 I_n$

Ковариационная матрица случайных ошибок является классической

МНК-оценки коэффициентов:  $\hat{\beta} = (X^T X)^{-1} X^T Y$

Ковариационная матрица МНК-оценок:  $V(\hat{\beta}) = \sigma^2 (X^T X)^{-1}$

Мультиколлинеарность может быть полная и частичная. На практике встречается только частичная.

### 2.1 Полная мультиколлинеарность

$\text{rank} X < k \iff \det(X^T X) = 0$ , то есть столбцы матрицы связаны линейной зависимостью:

$\exists c = (c_1, \dots, c_k)^T, c \neq O_k : c_1 X^{(1)} + \dots + c_k X^{(k)}$  или  $c^T X = O^T$

Встречается редко, когда на этапе спецификации мы не замечаем связи между регрессорами. В таком случае МНК не может быть реализован. С ней легко бороться: необходимо удалить лишние регрессоры.

### 2.2 Частичная (практическая) мультиколлинеарность

$\det(X^T X) \approx 0$

Какая-то из переменных очень близка к линейной комбинации остальных.

## 2.3 Признаки мультиколлинеарности

1. Малое значение  $\det(X^T X)$
2. Матрица парных коэффициентов корреляций  $\hat{R} = (\hat{r}_{ij})_{i,j} = 1, \dots, k$  содержит числа близкие к 1. Один регрессор сильно связан с другим
3. Среди коэффициентов детерминации  $R^2(x^{(j)}/X(j)), j = 1, \dots, k$  одного регрессора по остальным есть близкие к 1 ( $X(j)$  - набор объясняющих переменных, всех, кроме  $x^{(j)}, (\dim X(j) = k - 1)$ )

Пояснение к п. 3:

В матрице  $V(\hat{\beta}) = \sigma^2(X^T X)^{-1}$  на главной диагонали стоят дисперсии

$$D\hat{\beta}_j = \frac{\sigma^2}{n(1 - R^2(x^{(j)}/X(j))}, [s.e.(\hat{\beta}_j)]^2 = S_{\hat{\beta}_j}^2 = \frac{\hat{\sigma}^2}{n(1 - R^2...)}, \text{ где } \hat{\sigma}^2 = S^2 = \frac{ESS}{n - k}$$

s.e. - большие  $\Rightarrow t_{\text{стат}}$  - маленькие  $\Rightarrow$  оценки коэффициентов незначимы  
(много незначущих факторов в модели)

## 2.4 Последствия мультиколлинеарности

– Неустойчивость оценок коэффициентов к составу исходных данных (если в выборке изменить одну-две пары  $x$  и  $y$ , то значимые оценки могут стать незначимыми и наоборот)

Пример:  $y_i = x_i + 2z_i + \varepsilon_i$

Пусть  $x \approx 2z$  (если  $r(x, z) \approx 1$ )

Тогда могут быть эквивалентные представления модели:

$$y_i = 4z_i + \varepsilon'_i, y_i = -x_i + 6z_i + \varepsilon''_i, y_i = 5x_i + 6z_i + \varepsilon'''_i$$

Разные исследователи будут получать существенно разные выводы

- Знаки оценок меняются
- Большие значения стандартных ошибок (дисперсий)

## 2.5 Как бороться с мультиколлинеарностью?

Три подхода:

- Гребневая регрессия (смещенное оценивание коэффициентов)
- Метод главных компонент (переход к некоррелированным регрессорам)
- Снижение размерности пространства регрессоров (отбор наиболее информативных объясняющих переменных) - **самый распространенный метод**

### 2.5.1 Гребневая регрессия

Отказ от МНК-оценивания, переход к смещенному оцениванию коэффициентов:

Вместо  $\hat{\beta}_{\text{мнк}} = (X^T X)^{-1} X^T Y$  вводим класс оценок  $\hat{\beta}(\alpha) = (X^T X + \alpha I_k)^{-1} X^T Y$

В частности,  $\hat{\beta}(0) = \hat{\beta}_{\text{мнк}}$  - несмещенная оценка

$$E\hat{\beta}(\alpha) = \beta + \delta(\alpha), \delta(\alpha) \neq 0 \text{ при } \alpha \neq 0$$

Утв.  $\exists \alpha_0 \neq 0 : E(\hat{\beta}(\alpha_0) - \beta)^2 < E(\hat{\beta}_{\text{мнк}} - \beta)^2$  - найдется  $\alpha$ , у которой средний квадрат отклонения меньше, чем у МНК-оценки.

На практике  $\alpha$  находят методом подбора. Чаще всего при  $0,2 < \alpha < 0,4$  достигается минимум средне-квадратичной оценки.

### 2.5.2 Метод главных компонент

Временный переход к некоррелированным данным:

1) Центрирование исходных данных

$$\{(y_i, x_i^1, \dots, x_i^k, k = 1, \dots, n) \Rightarrow \{(\tilde{y}_i, \tilde{x}_i^1, \dots, \tilde{x}_i^k, k = 1, \dots, n)\}$$

$$\tilde{y}_i = y_i - \bar{y}, \tilde{x}_i^{(j)} = x_i^{(j)} - \bar{x}^{(j)}$$

2) Построение главных компонент для центрированных регрессоров

$$\tilde{x}_i^1, \dots, \tilde{x}_i^k \Rightarrow f^{(1)}, \dots, f^{(k)}$$

Каждая главная компонента является линейной комбинацией переменных  $\tilde{x}_i^1, \dots, \tilde{x}_i^k$

- Все главные компоненты попарно некоррелированы

- По главным компонентам можно однозначно восстановить исходные регрессоры (и наоборот)

3) Построение регрессии  $\tilde{y}$  по  $f^{(1)}, \dots, f^{(k)}$

$$\tilde{y}_i = c_1 f_i^{(1)} + \dots + c_k f_i^{(k)} + \sum_i$$

4) Возврат к  $\tilde{x}_i^1, \dots, \tilde{x}_i^k$

Результат: регрессия  $y$  по  $x_i^1, \dots, x_i^k$

### 2.5.3 Отбор наиболее информативных регрессоров (снижение размерности)

- Метод пошаговой регрессии

- Метод полного перебора регрессий

$p = k - 1$  – количество структурных регрессоров (априорный набор регрессоров  $x^{(2)}, \dots, x^{(k)}$ )

Перебор моделей по числу выбранных регрессоров:  $p = 1, 2, \dots, p$

Два варианта перебора: с увеличением и уменьшением числа объясняющих переменных

#### Полный перебор с добавлением регрессоров

$p = 1 : R^2(y/x^{(j)}) \rightarrow \max_{j=1, \dots, p} = R^2(1)$  - построение всех возможных регрессий, когда  $y$  зависит только от одного  $x$

$p = 2 : R^2(y/x^{(j_1)}, x^{(j_2)}) \rightarrow \max_{j_1, j_2=1, \dots, p, j_1=j_2-2} = R^2(2)$  - повторение для двух  $x$  и так далее

Последовательность  $R^2(p)$  не убывает

Правило остановки:

(i) Прирост  $R^2(p+1) - R^2(p)$  стал статистически незначимым

(ii)  $R_{adj}^2$  достиг своего максимума

(iii) Нижняя доверительная граница для  $R_{adj}^2$  достигла максимума. **Самый правильный вариант**

#### Частичный перебор

Пошаговая регрессия.

Отличие от полного перебора: при переходе к следующему шагу ( $p+1$ ) один из иксов выбирается таким, какой был на предыдущем шаге, это снижает количество переборов.

На практике отбор регрессоров происходит методом исключения незначимых переменных

## 3 Обобщенная ЛММР, обобщенный МНК

$$Y = X\beta + \varepsilon$$

$X$  – детерминированная ( $n \times k$ ),  $\text{rank} X = k, k < n$

$$E\varepsilon = O_n, V(\varepsilon) = \Omega$$

Техническое условие:  $\Omega > 0$  – положительная определенность

Свойства:

$$1) \Omega^T = \Omega$$

$$2) \exists \Omega^{-1}, \Omega^{-1} > 0$$

$$3) \exists P \text{ невырожденная } (n \times n) : \Omega^{-1} = P^T P$$

Два метода оценивания: МНК, ОМНК

### 3.1 МНК для КЛММР и ОЛММР

Критерий:  $(Y - Xb)^T(Y - Xb) \rightarrow \min_b$

Оценка:  $\hat{\beta}_{\text{МНК}} = (X^T X)^{-1} X^T Y$

Свойства:

- Несмещенность  $E\hat{\beta}_{\text{МНК}} = \beta$  (используется только  $E\varepsilon = O_n$ )
- Состоятельность  $\frac{1}{n} X^T X \rightarrow Q_{x^T x} > 0$
- Линейность по  $Y$
- Оптимальность в случае КЛММР (теорема Гаусса-Маркова)
- Неоптимальность в случае ОЛММР

**Что делать?**

Если  $V(\varepsilon) = \sigma^2 I_n$ , то  $V(\hat{\beta}_{\text{МНК}}) = \sigma^2 (X^T X)^{-1}$

В этом случае  $\hat{\sigma}_{\text{МНК}}^2 = \frac{1}{n-k} (Y - X\hat{\beta}_{\text{МНК}})^T (Y - X\hat{\beta}_{\text{МНК}})$  - несмещенная оценка для  $\sigma^2$

Если  $V(\varepsilon) = \Omega (\Omega > 0)$ , то  $V(\hat{\beta}_{\text{МНК}}) = (X^T X)^{-1} X^T \Omega X (X^T X)^{-1}$

Что в случае ОЛММР оценивает формула  $\hat{\sigma}_{\text{МНК}}^2$ ? Сигмы нет, формула ничего не оценивает

Надо уметь состоятельно оценивать матрицу  $\Omega$

### 3.2 ОМНК для ОЛММР

(1)  $Y = X\beta + \varepsilon$  - ОЛММР (2)  $PY = PX\beta + P\varepsilon$  - КЛММР

ОМНК для модели (1) это МНК, примененный к преобразованным данным, то есть к модели (2)

Критерий:

$(PY - PXb)^T (PY - PXb) \rightarrow \min_b$

$(Y - Xb)^T P^T P (Y - Xb) = (Y - Xb)^T \Omega^{-1} (Y - Xb) \rightarrow \min_b$

Оценка:

$\hat{\beta}_{\text{ОМНК}} = [(PX)^T (PX)]^{-1} (PX)^T (PY) = (X^T \Omega^{-1} X)^{-1} X^T \Omega^{-1} Y$

Свойства ОМНК оценок:

- Несмещенность  $E\hat{\beta}_{\text{ОМНК}} = \beta$
- Состоятельность
- Линейность по  $Y$
- Оптимальность (теорема Айткена)

$V(\hat{\beta}_{\text{ОМНК}}) = (X^T \Omega^{-1} X)^{-1}$

Есть ковариационная матрица  $V(\varepsilon) = \Omega$  неизвестна,

то ОМНК-оценка  $\hat{\beta}_{\text{ОМНК}} = (X^T \Omega^{-1} X)^{-1} X^T \Omega^{-1} Y$  не реализуема

**Частный случай:**  $\Omega = \sigma^2 \Omega_0$

$\sigma^2$  - неизвестный параметр

$\Omega_0 > 0$  - известная матрица  $\exists P_0 : \Omega_0^{-1} = P_0^T P_0$

$\hat{\beta}_{\text{ОМНК}} = (X^T \Omega_0^{-1} X)^{-1} X^T \Omega_0^{-1} Y$  - реализуемая оценка

Критерий:  $(Y - Xb)^T \Omega_0^{-1} (Y - Xb) \rightarrow \min_b$

Ковариационная матрица:  $V(\hat{\beta}_{\text{ОМНК}}) = \sigma^2 (X^T \Omega_0^{-1} X)^{-1}$

**Оценивание  $\sigma^2$  в рамках ОЛММР с  $V(\varepsilon) = \sigma^2 \Omega_0$**

Модель (2):  $P_0 Y = P_0 X \beta + P_0 \varepsilon, E(P_0 \varepsilon) = O$

$V(P_0 \varepsilon) = E(P_0 \varepsilon)(P_0 \varepsilon)^T = P_0 E(\varepsilon \varepsilon^T) P_0^T = P_0 \sigma^2 \Omega_0 P_0^T = \sigma^2 P_0 (P_0^T P_0)^{-1} P_0^T = \sigma^2 I_n$

Критерий:  $(P_0 Y - P_0 X b)^T (P_0 Y - P_0 X b) \rightarrow \min_b$

Оценка  $\sigma^2$

$\hat{\sigma}_{\text{ОМНК}}^2 = \frac{1}{n-k} (P_0 Y - P_0 X \hat{\beta}_{\text{ОМНК}})^T (P_0 Y - P_0 X \hat{\beta}_{\text{ОМНК}}) = \frac{1}{n-k} (Y - X \hat{\beta}_{\text{ОМНК}})^T \Omega_0^{-1} (Y - X \hat{\beta}_{\text{ОМНК}})$

### Коэффициент детерминации $R^2$ в обобщенной ЛММР

$$R^2 = 1 - \frac{ESS}{TSS}$$

$$R^2 = 1 - \frac{(Y - X\hat{\beta}_{\text{ОМНК}})^T \Omega_0^{-1} (Y - X\hat{\beta}_{\text{ОМНК}})}{(Y - \bar{Y}_i)^T \Omega_0^{-1} (Y - \bar{Y}_i)}$$

$R^2$  скорее всего не имеет смысла, так как в преобразованной матрице вида  $PX$  столбец единиц отсутствует.

### 3.3 Выводы:

Выбор метода оценивания зависит от предпосылок модели.

Надо максимально учитывать специфику модели, в частности, учесть характер зависимости регрессионных ошибок.

Если мы знаем  $\Omega$ , то можно применить ОМНК, он даст нам лучшие несмещенные, линейные оценки.

МНК тоже даст несмещенные, состоятельные, линейные, но не наилучшие оценки.

### 3.4 Частный случай: ЛММР с гетероскедастическими (и некоррелированными) ошибками

Гетероскедастичность: дисперсии случайных ошибок значительно различаются

$$(1) Y = X\beta + \varepsilon, V(\varepsilon) = \Omega \quad \Omega = \begin{pmatrix} \sigma_1^2 & & 0 \\ & \dots & \\ 0 & & \sigma_n^2 \end{pmatrix}, D\varepsilon_i = \sigma_i^2 \neq \text{const}$$

$$\Omega^{-1} = \begin{pmatrix} \frac{1}{\sigma_1^2} & & 0 \\ & \dots & \\ 0 & & \frac{1}{\sigma_n^2} \end{pmatrix}, P = \begin{pmatrix} \frac{1}{\sigma_1} & & 0 \\ & \dots & \\ 0 & & \frac{1}{\sigma_n} \end{pmatrix}$$

$$(1) Y = X\beta + \varepsilon \implies (2) PY = PX\beta + P\varepsilon$$

$$(1) y_i = \beta_1 x_i^{(1)} + \dots + \beta_k x_i^{(k)} + \varepsilon_i \quad (2) \frac{y_i}{\sigma_i} = \frac{\beta_1 x_i^{(1)}}{\sigma_i} + \dots + \frac{\beta_k x_i^{(k)}}{\sigma_i} + \frac{\varepsilon_i}{\sigma_i}$$

ОМНК  $\equiv$  ВМНК (взвешенный МНК, weight least squares)

$$\text{Критерий: } \sum_{i=1}^n \frac{1}{\sigma_i^2} (y_i - \beta_1 x_i^{(1)} - \dots - \beta_k x_i^{(k)}) \longrightarrow \min_b$$

Суть: если  $\sigma_i$  большое, то  $i$ -ое уравнение включается в сумму с маленьким весом

Имеем  $n + k$  параметров модели:

$\beta_1, \dots, \beta_k$  и  $\sigma_1^2, \dots, \sigma_n^2$ , но  $n$  наблюдений  $\implies$  состоятельно оценить все (независимые) параметры нельзя  
Но если  $\sigma_1^2, \dots, \sigma_n^2$  выражаются через некоторое (небольшое) количество параметров, то состоятельно оценить можно

**Что делать?**  $\Omega = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$

$\Omega$  известна  $\rightarrow$  ВМНК

$\Omega$  неизвестна  $\rightarrow$  Форма гетероскедастичности  $\rightarrow$  Известна  $\rightarrow$  Двухшаговая процедура

$\rightarrow$  Неизвестна  $\rightarrow$  МНК-оценки + поправки Уайта

Функциональная форма гетероскедастичности:

$$\sigma_i^2 = f(z_i^{(1)}, \dots, z_i^{(p)}), \text{ где } z - \text{некоторые из иксов или функции от них}$$

### 3.4.1 Поправки Уайта

(ОЛММР + МНК)

$\hat{\beta}_{\text{МНК}}$  - несмещенные, состоятельные (но не оптимальные) оценки

$s.e.(\hat{\beta}_{j,\text{МНК}}) = \sqrt{\hat{\sigma}_{\text{МНК}}^2 [(X^T X)^{-1}]}$  - несостоятельные оценки

$h.c.s.e.(\hat{\beta}_{j,\text{МНК}})$  стандартные ошибки, поправленные с учетом гетероскедастичности

Они являются состоятельными оценками стандартных отклонений

**Оценивание ковариационной матрицы вектора МНК-оценок  $\beta$  по Уайту:**

$$\hat{V}(\hat{\beta}_{\text{МНК}}) = (X^T X)^{-1} X^T \hat{\Omega} X (X^T X)^{-1}$$

где  $\hat{\Omega} = \text{diag}(e_1^2, \dots, e_n^2)$ ,  $e_i$  - МНК-остаток

$$X^T \text{diag}(e_1^2, \dots, e_n^2) X = \sum_{s=1}^n e_s^2 X_s X_s^T - (k \times k) \text{ матрица}$$

где  $X_s = (X_s^{(1)}, \dots, X_s^{(k)})^T$  -  $s$ -я строка матрицы  $X$ , поставленная в столбец

### 3.4.2 Двухшаговая процедура оценивания параметров гетероскедастической ОЛММР

$$(1) Y = X\beta + \epsilon, V(\epsilon) = \Omega = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$$

Постулируем линейную форму гетероскедастичности:

$$\sigma_i^2 = \gamma_0 + \gamma_1 z_i^{(1)} + \dots + \gamma_p z_i^{(p)} = \gamma_0 + Z_i \gamma \quad (\text{пусть это истинная, правильно угаданная форма})$$

**Шаг 1.** Применение классического МНК

1) МНК (1), получаем остатки и оценку:  $\hat{\beta}, e_1, \dots, e_n \Rightarrow e_i^2$

2) Оцениваем вспомогательную регрессию

$$e_i^2 = \gamma_0 + Z_i^T \gamma + \text{ошибка}$$

$$\text{МНК} \Rightarrow \hat{\gamma}_0, \hat{\gamma}$$

Доказанный факт:  $\hat{\gamma}_0, \hat{\gamma}$  оценки состоятельны

3) получаем окончательные оценки для  $\sigma^2$ :  $\hat{\sigma}_i^2 = \hat{\gamma}_0 + Z_i^T \hat{\gamma}$

**Шаг 2.** Оценка  $\beta$  в модели (1) доступным (реализуемым) ОМНК, то есть применяем взвешенный МНК, в котором вместо весов  $1/\sigma_i^2$  берем  $1/\hat{\sigma}_i^2$

Оценки  $\hat{\beta}$  не являются оптимальными, но они асимптотически оптимальны

**Замечание:**

Взвешенный МНК это обычный МНК, примененный к преобразованным данным

$$(y_i, x_i^{(1)}, \dots, x_i^{(k)}) \rightarrow \left( \frac{y_i}{\hat{\sigma}_i}, \frac{x_i^{(1)}}{\hat{\sigma}_i}, \dots, \frac{x_i^{(k)}}{\hat{\sigma}_i} \right)$$

**Проблема:**  $\hat{\sigma}_i = \sqrt{\hat{\sigma}_i^2}$

Не  $\hat{\sigma}_i^2$  все могут оказаться положительными

**Что делать?**

- выкидывать те  $i$ , для которых  $\hat{\sigma}_i^2 \leq 0$

**Некорректный способ, так как выбор выкидываемых наблюдений не случаен**

На практике пытаются использовать не аддитивную, а мультипликативную форму гетероскедастичности вида:  $\hat{\sigma}_i^2 = \exp\{\gamma_0 + \gamma_1 z_i^{(1)} + \dots + \gamma_p z_i^{(p)}\} = e^{\gamma_0 + Z_i^T \gamma}$

### 3.4.3 Двухшаговая процедура доступного ОМНК-оценивания параметров обобщенной модели (1) с экспоненциальной формой гетероскедастичности

**Шаг 1.**

1) МНК (1)  $\hat{\beta}_{\text{МНК}} \Rightarrow e$  - МНК-остатки

2) Постулируем форму гетероскедастичности

$$\sigma_i^2 = \exp\{\gamma_0 + Z_i^T \gamma\}, \text{ т.е. } \ln(\sigma_i^2) = \gamma_0 + Z_i^T \gamma$$

Оцениваем вспомогательную регрессию



$$\ln(\sigma_i^2) = \gamma_0 + Z_i^T \gamma + \text{ошибка}_i$$

Получаем состоятельные МНК-оценки  $\hat{\gamma}_0, \hat{\gamma}$ , параметров  $\gamma_0, \gamma$

Получаем состоятельные оценки дисперсий регрессионных ошибок  $\hat{\sigma}_i^2 =$ , параметров  $\gamma_0, \gamma$

3) Получаем окончательные оценки для  $\sigma^2 = \exp\{\hat{\gamma}_0 + Z_i^T \hat{\gamma}\} > 0$

### Шаг 2.

Оцениваем  $\beta$  в модели (1) доступным ОМНК (проблемы отрицательных оценок дисперсий  $\sigma^2$  здесь нет)

1. До двухшаговой процедуры: есть ли гетероскедастичность в ошибках?

2. После двухшаговой процедуры: избавились ли мы от гетероскедастичности?

Если форма гетероскедастичности ошибок  $\varepsilon_1, \dots, \varepsilon_n$  исходной модели  $y_i = \beta_1 x_i^{(1)} + \dots + \beta_k x_i^{(k)}$  оценена

правильно, то в модели для преобразованных данных  $\frac{y_i}{\sigma_i} = \frac{\beta_1 x_i^{(1)}}{\sigma_i} + \dots + \frac{\beta_k x_i^{(k)}}{\sigma_i} + \frac{\varepsilon_i}{\sigma_i}$  ошибки станут гомоскедастическими.